

CYBERGUARD AI

AUTONOMOUS SECURITY OPERATIONS CENTER

Rapport Technique :

Intégration de pipelines RAG, *Reasoning Agents*
et architecture Groq LPU sécurisée.

Réalisé par :

Nour CHARGUI
Anissa GHARBI

Étudiantes en Cycle Ingénieur

Classe : ING-3-J-M

Année Universitaire 2024 – 2025

Résumé

Ce rapport détaille la conception de **CyberGuard AI**, un assistant SOC intelligent exploitant la puissance d'inférence de **Groq** et la fiabilité du **RAG (Retrieval-Augmented Generation)**. L'innovation du projet réside dans son architecture *Privacy-First* : l'anonymisation des données sensibles par Regex et l'utilisation d'embeddings locaux garantissent que les informations critiques de l'infrastructure ne sont jamais exposées. Le système, propulsé par **FastAPI** et **React**, offre une réponse quasi instantanée aux cybermenaces grâce à l'accélération LPU de Groq.

Table des matières

1	Introduction Générale	3
1.1	Contexte et Motivation	3
1.2	Problématique	3
1.3	Objectifs du Projet	3
2	Étude Technique de la Stack IA	4
2.1	Architecture Globale du Système	4
2.1.1	Schéma de l'Architecture Multicouche	4
2.2	Justification des choix technologiques	5
3	Intelligence Artificielle et Pipeline RAG	6
3.1	Le Moteur de Recherche Sémantique (RAG)	6
3.2	L'Agent IA : La boucle de raisonnement (Reasoning Loop)	6
4	Conception Orientée Sécurité	7
4.1	Anonymisation (Privacy by Design)	7
4.2	Optimisation des Performances	7
5	Scénarios d'Utilisation et Validation	8
5.1	Scénario 1 : Analyse de Vulnérabilité SSH	8
5.2	Scénario 2 : Détection de Menace Critique (RCE)	8
5.3	Scénario 3 : Protection des Données Sensibles	9
6	Réalisation du Frontend SOC	10
6.1	Dashboard Analyste	10
	Conclusion et Perspectives	11

Chapitre 1

Introduction Générale

1.1 Contexte et Motivation

La cybersécurité moderne fait face à une explosion du volume de logs et à une sophistication accrue des attaques. Les analystes SOC souffrent d'une "fatigue des alertes", où le bruit numérique masque souvent des signaux critiques.

1.2 Problématique

Les solutions d'IA classiques basées uniquement sur le Cloud posent deux problèmes majeurs : les **hallucinations** (réponses inventées) et la **confidentialité**. Ce projet vise à créer un assistant capable de raisonner uniquement sur des données vérifiées et sécurisées.

1.3 Objectifs du Projet

L'objectif est d'implémenter un pipeline IA capable de :

- Réduire le **MTTR** (Mean Time To Respond) via une analyse automatisée.
- Assurer une précision technique grâce à un moteur RAG.
- Garantir la souveraineté des données via une architecture hybride Cloud/Local.

Chapitre 2

Étude Technique de la Stack IA

2.1 Architecture Globale du Système

L'architecture de **CyberGuard AI** repose sur une approche **AI-Oriented Architecture** découplée. Le backend asynchrone orchestre les flux entre la base vectorielle locale et le moteur d'inférence haute vitesse.

Vision Architecturale

Responsabilités des composants :

- **Frontend React** : Interface de monitoring et chat interactif.
- **Backend FastAPI** : Orchestrateur et passerelle sécurisée.
- **Moteur RAG** : Indexation et recherche sémantique locale.
- **LLM Groq (Llama 3)** : Cerveau décisionnel à ultra-haute vitesse.

2.1.1 Schéma de l'Architecture Multicouche




FIGURE 2.1 – Architecture globale multicouche de CyberGuard AI

2.2 Justification des choix technologiques

- **Groq Cloud (Llama 3.3 70B)** : Contrairement aux APIs classiques, Groq utilise des LPUs (*Language Processing Units*) permettant une vitesse d'inférence 10x supérieure, essentielle pour une réponse SOC en temps réel.
- **ChromaDB** : Base de données vectorielle *Native-AI*, choisie pour sa capacité de persistance locale et sa rapidité de recherche sémantique.
- **FastAPI** : Utilisation du mode asynchrone pour gérer les appels LLM sans bloquer les requêtes des autres analystes.

Chapitre 3

Intelligence Artificielle et Pipeline RAG

3.1 Le Moteur de Recherche Sémantique (RAG)

Le RAG permet de fournir au modèle Llama 3 un contexte spécifique issu de nos documents de sécurité (PDFs, logs, manuels).




FIGURE 3.1 – Pipeline d’ingestion et de génération augmentée

3.2 L’Agent IA : La boucle de raisonnement (Reasoning Loop)

L’agent n’est pas un simple chatbot ; il implémente la logique **ReAct** (Reasoning + Acting). Il décompose chaque requête complexe en sous-tâches, décide d’appeler l’outil RAG pour chercher une solution, ou l’outil d’analyse de criticité pour évaluer un log.

Chapitre 4

Conception Orientée Sécurité

4.1 Anonymisation (Privacy by Design)

Le middleware d'anonymisation intercepte les messages avant leur sortie vers l'API Groq.

Listing 4.1 – Script d'anonymisation Regex

```
def anonymize_text(self, text: str) -> str:
    # Masquage IP IPv4
    text = re.sub(r'\b\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}\b', "[
        IP_ANONYME]", text)
    # Masquage Emails
    text = re.sub(r'\S+@\S+', "[EMAIL_MASQUE]", text)
    return text
```

4.2 Optimisation des Performances

L'intégration du modèle **all-MiniLM-L6-v2** pour les embeddings permet une vectorisation ultra-rapide en local (CPU), évitant les coûts et la latence des APIs d'embeddings cloud.

Chapitre 5

Scénarios d'Utilisation et Validation

5.1 Scénario 1 : Analyse de Vulnérabilité SSH

Action : L'utilisateur demande : "Comment sécuriser le port 22?".

Processus IA : L'agent déclenche l'outil `search_knowledge_base`. Il extrait du fichier `cyber_docs.txt` les règles sur les clés RSA 4096. Groq génère ensuite une réponse structurée recommandant la désactivation des mots de passe.

- **Requête :** "Comment sécuriser l'accès SSH sur nos serveurs?"
- **Action IA :** Extraction sémantique depuis `cyber_docs.txt`.
- **Résultat :** L'IA préconise l'usage de clés RSA 4096 bits et la désactivation de l'accès root.




FIGURE 5.1 – Capture d'écran du Scénario 1 : Réponse augmentée par le RAG sur la sécurité SSH

5.2 Scénario 2 : Détection de Menace Critique (RCE)

Action : L'analyste soumet un log suspect contenant des patterns d'injection.

Processus IA : L'agent appelle l'outil `analyze_vulnerability_level`. Il identifie un risque de *Remote Code Execution* (RCE) et retourne immédiatement un score de **9.8/10**

avec une procédure d'isolement du serveur.

- **Requête** : "Analyse ce log : Tentative d'injection sur le endpoint /admin."
- **Outil activé** : `analyze_vulnerability_level`.
- **Résultat** : L'Agent identifie une menace critique, attribue un score CVSS de 9.8 et propose un script d'isolement.

5.3 Scénario 3 : Protection des Données Sensibles

Action : Un log est soumis avec une IP réelle.

Preuve technique : Le rapport affiche que l'IA a traité la requête, mais les logs serveurs montrent que seule la version anonymisée a été transmise à Groq.

- **Donnée soumise** : "Alerte sur l'hôte 192.168.1.50 (user : admin@entreprise.com)".
- **Traitement** : Application immédiate des filtres Regex en backend.
- **Résultat** : L'IA traite la demande en utilisant uniquement les tokens `[IP_HIDDEN]` et `[EMAIL_MASQUE]`.




FIGURE 5.2 – Capture d'écran du Scénario 3 : Preuve d'anonymisation des données avant traitement LLM

Chapitre 6

Réalisation du Frontend SOC

6.1 Dashboard Analyste

Le dashboard utilise **Tailwind CSS** pour un rendu sombre (Slate-950) minimisant la fatigue visuelle. L'interface sépare les modules de "L'Anonymiseur" et de "L'Analyseur de logs".




FIGURE 6.1 – Interface de CyberGuard AI montrant une réponse basée sur Groq

Conclusion et Perspectives

CyberGuard AI prouve que l'IA générative peut être un allié de confiance en cybersécurité si elle est encadrée par une architecture RAG rigoureuse. L'utilisation de Groq a permis de supprimer la latence, rendant l'outil utilisable en situation de crise.

Les perspectives incluent le déploiement de modèles totalement locaux (via Ollama) pour les infrastructures critiques hors-ligne.

Bibliographie

- [1] Groq LPU Architecture, *Next-gen AI Inference*, 2024.
- [2] FastAPI Documentation, *Async Python Framework*, 2024.
- [3] Lewis et al., *Retrieval-Augmented Generation*, 2020.